

TEMA 9-A: INTRODUCCIÓN AL PROCESAMIENTO DEL LENGUAJE NATURAL (PLN)

El procesamiento del lenguaje natural es la disciplina de la informática con orientación lingüística y se ocupa de la capacidad del software para comprender el lenguaje humano natural. Tanto escrito como hablado.

Dado que, cuando se trata de nuestro lenguaje natural, hay tal abundancia de diferentes tipos de entradas y escenarios, es imposible para cualquier desarrollador generar un programa para cada caso imaginable. Por lo tanto, para que el procesamiento del lenguaje natural en la IA funcione realmente, debe ser apoyado por el aprendizaje automático.

En pocas palabras, el aprendizaje automático permite que el algoritmo de PLN aprenda de cada nueva conversación y así se mejore de forma autónoma a través de la práctica.

La figura de la transparencia se muestra una relación muy interesante en la que se ve cómo el PLN es la intersección entre dos grandes categorías, la inteligencia artificial y la lingüística. A su vez se observa que el PLN tiene un componente de Aprendizaje Automático y Aprendizaje Profundo. Y, a su vez, del PLN se desprenden dos categorías principales: NLU (entendimiento del lenguaje natural) y NLG (generación del lenguaje natural).

¿Pero qué es concretamente el PLN?

El PLN describe la capacidad de una máquina para “ingerir” lo que se le dice, descomponerlo y comprender cuál es su significado. El objetivo es determinar una acción adecuada. Un ejemplo son los asistentes de voz de los televisores: una persona solicita al televisor un contenido (señal de entrada), la máquina interpreta dicho contenido y ejecuta una acción. La intención del PLN es diseñar mecanismos para comunicarse que sean eficaces computacionalmente. Es decir, que se puedan realizar por medio de programas informáticos y que ejecuten o simulen la comunicación.

¿Qué son NLU y NLG?

- **NLU (Natural Language Understanding)** es una rama de la inteligencia artificial que se centra en la capacidad de una máquina para comprender el lenguaje humano. Implica la interpretación del significado, contexto e intención detrás de una frase o conversación, permitiendo que los sistemas procesen y respondan a entradas en lenguaje natural de forma coherente.
- **NLG (Natural Language Generation)**, por otro lado, es el proceso de generación de texto en lenguaje natural por parte de una máquina. Su objetivo es convertir datos estructurados o información en texto que suene natural para los humanos, facilitando la creación de respuestas, descripciones o resúmenes.

TAREAS Y APLICACIONES DE PLN

Cada aplicación inteligente que involucra el lenguaje humano tiene algo de PNL detrás. Debido a la naturaleza abierta de los problemas de PNL, existen muchos enfoques alternativos que se pueden adoptar para resolver un problema determinado.

El PNL es un componente importante en una amplia gama de aplicaciones de software que utilizamos en nuestra vida diaria.

1. Las plataformas de correo electrónico, como Gmail, Outlook, etc., utilizan el PNL para proporcionar una variedad de funciones de producto, como clasificación de spam, bandeja de entrada prioritaria, extracción de eventos del calendario, autocompletar, etc.

2. Los asistentes basados en voz, como Apple Siri, Google Assistant, Microsoft Cortana y Amazon Alexa, se basan en una variedad de técnicas de PNL para interactuar con el usuario, comprender los comandos del usuario y responder en consecuencia.
3. Los motores de búsqueda modernos, como Google y Bing, utilizan intensamente el PNL para diversas sub tareas, como la comprensión de consultas, la expansión de consultas, la respuesta a preguntas, la recuperación de información y la clasificación y agrupación de los resultados, para nombrar unos pocos.
4. Los servicios de traducción automática, como Google Translate, Bing Microsoft Translator y Amazon Translate, se utilizan cada vez más en el mundo actual para resolver una amplia gama de escenarios y casos de uso empresarial. Estos servicios son aplicaciones directas del PNL.

Existen una gran cantidad de otras aplicaciones:

5. Las organizaciones analizan los feeds de sus redes sociales para generar una mejor comprensión de la opinión de sus clientes.
6. Las plataformas de comercio electrónico como Amazon utilizan PLN para extraer información relevante de las descripciones de los productos y de las reviews asociadas.
7. El PNL forma la columna vertebral de las herramientas de corrección ortográfica y gramatical, como Grammarly y el corrector ortográfico en Microsoft Word y Google Docs.
8. El PNL también se utiliza en una variedad de herramientas y tecnologías de aprendizaje y evaluación, como la puntuación automatizada en exámenes como el Graduate Record Examination (GRE), la detección de plagio (por ejemplo, Turnitin), los sistemas de tutoría inteligentes y las aplicaciones de aprendizaje de idiomas como Duolingo.
9. Finalmente, el PNL se utiliza para crear grandes bases de conocimiento, como Google Knowledge Graph, que son útiles en una variedad de aplicaciones como búsqueda y respuesta a preguntas.

Hay una colección de tareas fundamentales que aparecen con frecuencia en varios proyectos de PNL. Debido a su naturaleza repetitiva y fundamental, estas tareas se han estudiado en profundidad y tener un buen control sobre estas tareas nos va a facilitar el desarrollo posterior de aplicaciones de PNL.

La primera de estas tareas es el modelado de lenguaje. Esta es la tarea de predecir cuál será la siguiente palabra de una oración en función del historial de palabras anteriores. El objetivo de esta tarea es aprender la probabilidad de que aparezca una secuencia de palabras en un idioma determinado. El modelado de lenguaje es útil para crear soluciones para una amplia variedad de problemas, como reconocimiento de voz, reconocimiento óptico de caracteres, reconocimiento de escritura a mano, traducción automática y corrección ortográfica.

Tenemos también la clasificación de texto. Esta es la tarea de agrupar el texto en un conjunto conocido de categorías según su contenido. La clasificación de texto es, por lejos, la tarea más popular en PNL y se utiliza en una variedad de herramientas, desde la identificación de spam en correos electrónicos hasta el análisis de opiniones.

Otra tarea es la extracción de información. Como su nombre lo indica, se trata de la tarea de extraer información relevante del texto, como eventos del calendario de correos electrónicos o los nombres de las personas mencionadas en una publicación en las redes sociales.

Por otro lado, la recuperación de información es la tarea de encontrar documentos relevantes para la consulta de un usuario en una colección grande. Aplicaciones como la Búsqueda de Google son casos de uso bien conocidos de recuperación de información.

Tenemos también los agentes conversacionales. Ésta es la tarea de construir sistemas de diálogo que puedan conversar en lenguajes humanos. Alexa, Siri, etc., son algunas aplicaciones habituales de esta tarea.

Entrando a tareas más complejas encontramos el resumen de texto (que tiene como objetivo crear resúmenes breves de documentos más largos conservando al mismo tiempo el contenido principal y preservando el significado general del texto, la respuesta a preguntas, la traducción automática y el modelado de tópicos (que es la tarea de descubrir la estructura temática de una gran colección de documentos).

BLOQUES DE CONSTRUCCIÓN DEL LENGUAJE

Para estudiar PNL es importante comprender algunos conceptos de la lingüística sobre cómo se estructura el lenguaje. El lenguaje es un sistema estructurado de comunicación que involucra combinaciones complejas de sus componentes constituyentes, como caracteres, palabras, oraciones, etc. La lingüística es el estudio sistemático del lenguaje.

Podemos pensar que el lenguaje humano está compuesto por cuatro componentes básicos: fonemas, morfemas y lexemas, sintaxis y contexto. Las aplicaciones de PNL necesitan conocimiento de diferentes niveles de estos componentes básicos, desde los sonidos básicos del lenguaje (fonemas) hasta textos con algunas expresiones significativas (contexto).

La figura de la transparencia muestra estos componentes básicos del lenguaje, lo que abarcan y algunas aplicaciones de PNL que presentamos anteriormente y que requieren este conocimiento.

Analicemos cada uno de los bloques.

Los fonemas son las unidades más pequeñas de sonido en una lengua. Es posible que no tengan ningún significado por sí solos, pero pueden inducir significados cuando se pronuncian en combinación con otros fonemas. Los fonemas son particularmente importantes en aplicaciones que involucran la comprensión del habla, como el reconocimiento de voz, la transcripción de voz a texto y la conversión de texto a voz.

Un morfema es la unidad más pequeña del lenguaje que tiene un significado. Está formado por una combinación de fonemas. No todos los morfemas son palabras, pero todos los prefijos y sufijos son morfemas. Por ejemplo, en la palabra "multimedia", "multi-" no es una palabra sino un prefijo que cambia el significado cuando se combina con "media". "Multi-" es un morfema.

Los lexemas son variaciones estructurales de morfemas relacionados entre sí por su significado. Por ejemplo, "corre" y "correr" pertenecen a la misma forma de lexema. El análisis morfológico, que analiza la estructura de las palabras mediante el estudio de sus morfemas y lexemas, es un bloque fundamental para muchas tareas de PNL, como la tokenización, el stemming, el aprendizaje de embeddings y el etiquetado de partes del discurso, que vimos en el video de ingeniería de características textuales.

La sintaxis es un conjunto de reglas para construir oraciones gramaticalmente correctas a partir de palabras y frases en un idioma. La estructura sintáctica en lingüística se representa de muchas maneras diferentes. Un enfoque común para representar oraciones es un árbol de análisis. La sintaxis de un idioma puede ser muy diferente de la de otro idioma, y los enfoques de procesamiento del lenguaje necesarios para ese idioma cambiarán en consecuencia.

El contexto es cómo se unen varias partes de un idioma para transmitir un significado particular. El contexto incluye referencias a largo plazo, conocimiento del mundo y sentido común junto con el significado literal de palabras y frases. El significado de una oración puede cambiar según el contexto, ya que las palabras y frases a veces pueden tener múltiples significados. Generalmente, el contexto se compone de semántica y pragmática. La semántica es el significado directo de las palabras y oraciones sin contexto externo. La pragmática agrega conocimiento mundial y contexto externo de la conversación para permitirnos inferir el significado implícito. Las tareas complejas de PLN, como la detección de sarcasmo, el resumen y el modelado de temas, son algunas de las tareas que utilizan mucho el contexto.

DIFICULTADES

En general, el PLN es una tarea compleja. Una de las razones fundamentales es la ambigüedad. Una ambigüedad se da cuando una palabra o una expresión permite dos o más interpretaciones. Toda ambigüedad depende de su contexto, es decir, de la cantidad de información que tiene el receptor sobre aquello de lo que se habla. Para lograr un texto comprensible es importante evitar la ambigüedad y brindar elementos contextuales que no se presten a confusión.

Hay varios tipos de ambigüedad:

- Ambigüedad por polisemia. Se da cuando una palabra tiene más de un significado y no queda claro a cuál de todos se refiere. Por ejemplo: Es una persona noble. / Puede referirse a tener un título nobiliario o a tener la virtud de la nobleza.
- Ambigüedad por errores gramaticales (anfibología). Se da cuando no se comprende a cuál de los elementos de una oración refiere un determinado modificador. Por ejemplo: Cuando apoyamos el cuadro sobre la mesa, se rompió. / "se rompió" puede referirse al cuadro o a la mesa.
- Ambigüedad sintáctica. En la sintaxis de una frase, una misma palabra puede ocupar el lugar de adjetivo o adverbio, verbo o sustantivo, etc. Si no sabemos qué función cumple esa palabra, podemos no entender el sentido. Por ejemplo: Me vuelvo a cambiar. / Puede ser que la persona vuelva a un lugar para cambiarse o que se cambie dos veces.

Además de la ambigüedad existen otros desafíos:

(1) Palabras y frases contextuales y homónimos.

Las mismas palabras y frases pueden tener diferentes significados según el contexto de una oración y algunas palabras (aunque esto sucede especialmente en inglés), tienen exactamente la misma pronunciación, pero significados totalmente diferentes.

Por ejemplo: Braza Y Brasa

Estos son fáciles de entender para los humanos porque leemos el contexto de la oración y entendemos todas las diferentes definiciones. Y, si bien los modelos de lenguaje de PLN pueden haber aprendido todas las definiciones, diferenciarlas en contexto puede presentar problemas.

Los homónimos (dos o más palabras que se pronuncian de la misma manera, pero tienen diferentes definiciones) pueden ser problemáticos para las aplicaciones de respuesta a preguntas y de voz a texto porque no están escritos en forma de texto.

(2) Sinónimos

Los sinónimos pueden conducir a problemas similares a la comprensión contextual porque usamos muchas palabras diferentes para expresar la misma idea. Además, algunas de estas palabras pueden transmitir exactamente el mismo significado, mientras que otras pueden tener niveles de

complejidad (chico, pequeño, diminuto) y diferentes personas usan sinónimos para denotar significados ligeramente diferentes dentro de su vocabulario personal.

Por lo tanto, para crear sistemas de PLN, es importante incluir todos los posibles significados y sinónimos de una palabra. Los modelos de análisis de texto pueden cometer errores ocasionalmente, pero mientras más datos de entrenamiento relevantes reciban, mejor podrán comprender los sinónimos.

(3) Ironía y sarcasmo

La ironía y el sarcasmo presentan problemas para los modelos de aprendizaje automático porque generalmente usan palabras y frases que, estrictamente por definición, pueden ser positivas o negativas, pero en realidad connotan lo contrario.

Los modelos se pueden entrenar con ciertas señales que frecuentemente acompañan a frases irónicas o sarcásticas, como "sí, claro", "lo que sea", etc., e incrustaciones de palabras (donde las palabras que tienen el mismo significado tienen una representación similar), pero sigue siendo un complicado proceso.

(4) Errores en el texto y el habla

Las palabras mal escritas o mal utilizadas pueden crear problemas para el análisis de texto. Las aplicaciones de autocorrección y corrección gramatical pueden manejar errores comunes, pero no siempre comprenden la intención del escritor.

Con lenguaje hablado, mala pronunciación, diferentes acentos, tartamudeos, etc., puede ser difícil de entender para una máquina. Sin embargo, a medida que las bases de datos de idiomas crecen y los usuarios individuales capacitan a los asistentes inteligentes, estos problemas se pueden minimizar.

(5) Coloquialismos y jerga

Las frases, expresiones, modismos y jerga específicos de una cultura informal presentan una serie de problemas para la PLN, especialmente para los modelos destinados a un uso amplio. Porque, como lenguaje formal, los coloquialismos pueden no tener "definición de diccionario" en absoluto, y estas expresiones pueden incluso tener diferentes significados en diferentes áreas geográficas. Además, la jerga cultural se transforma y se expande constantemente, por lo que cada día surgen nuevas palabras.

Aquí es donde el entrenamiento y la actualización periódica de los modelos personalizados pueden resultar útiles, aunque a menudo requiere una gran cantidad de datos.

(6) Lenguaje específico del dominio

Las diferentes empresas e industrias a menudo utilizan un lenguaje muy diferente. Un modelo de procesamiento de PLN necesario para la atención médica, por ejemplo, sería muy diferente al utilizado para procesar documentos legales. En estos días, sin embargo, hay una serie de herramientas de análisis capacitadas para campos específicos, pero las industrias extremadamente específicas pueden necesitar construir o entrenar sus propios modelos.

(7) Idiomas de bajos recursos

Las aplicaciones de PLN de aprendizaje automático de IA se han creado en gran medida para los lenguajes más comunes y más utilizados. Y es realmente sorprendente lo precisos que se han vuelto los sistemas de traducción. Sin embargo, muchos idiomas, especialmente los que hablan las personas con menos acceso a la tecnología, a menudo se pasan por alto y no se procesan correctamente. Por ejemplo, según algunas estimaciones, (dependiendo del idioma frente al dialecto) hay más de 3.000 idiomas en África, solo. Simplemente, no hay muchos datos sobre muchos de estos idiomas.

Sin embargo, las nuevas técnicas, como los transformadores multilingües o los modelos grandes del lenguaje en general y las incorporaciones de oraciones multilingües, tienen como objetivo identificar y aprovechar las similitudes universales que existen entre los idiomas.

(8) Falta de investigación y desarrollo.

El aprendizaje automático requiere MUCHOS datos para funcionar hasta sus límites externos: miles de millones de datos de entrenamiento. Cuantos más datos se entrenan los modelos de PLN, más inteligentes se vuelven. Todos los problemas anteriores requerirán más investigación y nuevas técnicas para mejorarlos.

Las prácticas avanzadas como las redes neuronales artificiales y el aprendizaje profundo permiten que una multitud de técnicas, algoritmos y modelos de PLN funcionen de manera progresiva, al igual que lo hace la mente humana. A medida que crecen y se fortalecen, es posible que tengamos soluciones para algunos de estos desafíos en el futuro cercano.